

## הרצאה 2

שערוך אצווה (BATCH) בשיטת מינימום ריבועים בשיטת (minimum squares)

מודל לינארי:

מניח מדידה:

$$\underset{\text{scalar measurement}}{Z(k)} = \underset{\text{parametr vector}}{h(\eta)\theta} + \underset{\text{measurement noise}}{\mu(k)}$$

where  $E[\mu(k)] = 0$

אנחנו מניחים כי ממוצע הרעש הוא אפס (no bias)

בה"כ  $Z, K, \mu$  וקטורים.

ידוע לנו כי  $H$  דטרמיניסטי,  $Z$  הם המדידות הקיימות לנו. כיצד נוכל לשערך את וקטור הפרמטרים  $\theta$ ? וכיצד מוגדר  $\theta$  אופטימלית?

נביט במקרה בו :

$$\underset{\text{assumption}}{\theta(k)} \underset{\text{parameter vector till time } k}{} \rightarrow Z(k) = H(k)\theta + V(k) \underset{\text{we use mean of noise as closest approx}}{\approx} Z(k) + H(k)\theta(k)$$

בשיטת מינימום ריבועים ניתן לתת משקל לכל אחד מהפרמטים. פונקציית המחיר  $J$ :

$$J[\theta(k)] = \vec{Z}^T(k)W(k)\vec{Z}(k)$$

$$\text{def: } \vec{Z} = Z(k) - \hat{Z}(k)$$

*Equation error (residual)*

הערה: שגיאת השערוך היא  $Z$  ובמקרה הלינארי הזה גם שגיאת המשוואה

הערה:  $J$  הוא סקלר.

עבור  $W = I$  (מטריצת המשקל) מטריצת היחידה, נקבל את שיטת מינימום ריבועים (LS), אחרת שיטת מינימום ריבועים משקלית (WLS).

משום שנרצה למצוא את המשקל  $J$  כך שנקבל  $\theta$  מינימלית נגדיר

$$\text{def: } \hat{\theta}(k)_{LS} = \arg(\min(J[\theta(k)]))$$

הערה:  $W$  צריכה להיות (positive definite) PD אחרת מדידות מסוימות לא יילקחו בחשבון.

החוק שלוקח מדידות ומייצר מהם שערוך נקרא משערוך.

(where  $\theta$  is a random variable (or random process in time  $\hat{\theta}(k)$ )

$$J[\theta(k)] = [Z(w) - H(k)\hat{\theta}(k)]^T W(k) [Z(w) - H(w)\hat{\theta}(w)] =$$

$$Z^T(k)W(k)H(k) - 2Z^T(k)W(k)H(k)\hat{\theta}(k) + H^T(k)W(k)H(k)\hat{\theta}(k)$$

$$\text{REMINDER: } \frac{d(\vec{a}^T \vec{x})}{dx} = \vec{a} \text{ and } \frac{d\vec{X}^T A \vec{X}}{dx}$$

$$Z^T(k)W(k)Z(k) - 2Z^T(k)W(k)H(k)\hat{\theta}(k) + \hat{\theta}^T H^T(k)W(k)H(k)\hat{\theta}(k)$$

נגזור לקבלת  $J$  מינימלית שמתאימה ל $\theta$  מינימלית

$$\frac{dJ[\hat{\theta}(k)]}{d\theta(k)} = -2[Z^T(k)W(k)H(k)\hat{\theta}(k)]^T + 2[Z^T(k)W(k)H(k)\hat{\theta}(k)] = 0$$

$$Z^T(k)W(k)H(k)\hat{\theta}(k) = Z^T(k)W(k)H(k)$$

Where  $H$  is full rank, we arrive at

$$\hat{\theta}(k)_{WLS}(k) = [H(k)^T W(k) H(k)]^{-1} H(k)^T W(k) Z(k)$$

זוהי מדידה לא טובה כי  $H$  - עולה בריבוע משמע אין

$$\hat{\theta}(k)_{LS}(k) = [H(k)^T H(k)]^{-1} H(k)^T Z(k)$$

כאשר  $H$  איננה ריבועית לא קיימת מטריצה הופכית של  $H$  ועל כן נשתמש pseudo inverse. (קירוב למט' הופכית לא) נבדוק שהתשובה שלנו היא אכן מינימום לפי נגזרת שניה (הסיאן):


$$\frac{d^2(J(\hat{\theta}(k)))}{d^2\hat{\theta}} = 2Z^T(k)W(k)H^T(k) > 0 \rightarrow \text{minimum}.$$

כדי לפשט את החישובים נניח כי  $W = I$ :

$$H^T(k)H(k)\hat{\theta}(k)_{WLS} = H^T(k)Z(k)$$

נוציא את  $H^T$  מחוץ לסוגריים ונקבל:

$$[H^T(k)][Z(k) - H(k)\hat{\theta}(k)] = 0 \rightarrow H^T(k)\vec{Z}(k) = 0 \rightarrow \vec{Z} \in \ker H^T(k) \underset{\perp R[H^T(k)]}{\perp R[H^T(k)]}$$




טענה (הוכחה לפי הכלה משני הכיוונים):

$$\ker H^T(k) = R(H(k)^\perp)$$

טענה שקולה היא ש:

$$\vec{Z}(k) \in R(H)^\perp$$

עבור  $Z$  המדידה שלנו נרצה למצוא את המרחק הקטן ביותר (מינימום מרחק), זוהי בעיית אורטוגונליות, נוריד אנך ונקבל שגיאה מינימלית.



אושמן המליץ על ספר Lawson & Hanson solving least square problems לפתרון נומרי של בעיות מינימום ריבועים.

דוגמה לשערוך טתא ממדידות חסרות קורלציה:

$$Z(k) = \theta + V(k), \quad K = 1, \dots, N$$

where H is a matrix of ones

$$\hat{\theta}_{LS} = (H^T H)^{-1} H^T Z = \frac{1}{N} \sum_{i=1}^N Z(i)$$

בעיית מינימום ריבועים רקורסיבית (RLS)

שיטה: נוסף לוקטור המקורי את המשוואה בזמן  $k+1$

$$\begin{aligned} Z(k+1) &= h^T(k+1)\theta + V(k+1) \\ &+ \\ Z(k) &= H^T(k)\theta + V(k) \end{aligned}$$

$$\hat{\theta}_{WLS}(k+1) = [H(k+1)^T W(k+1) H(k+1)]^{-1} H(k+1)^T W(k+1) Z(k+1)$$

נניח כי  $W$  אלכסונית - בשיטה זו ההנחה הכרחית משום שבלעדיה לא ניתן להניח את שלמות שיטת מינימום הריבועים הרקורסיבית.

$$W(k+1) = \begin{bmatrix} W(k+1) & 0 \\ 0 & W(k) \end{bmatrix}$$

$$P \stackrel{def}{=} H^T(k+1)W(k+1)H(k+1) = [h(k) \quad H^T(k)] \begin{bmatrix} W(k+1) & 0 \\ 0 & W(k) \end{bmatrix} [h(k) \quad H^T(k)]^T$$

$$= h(k+1)W(k+1)h^T(k+1) + H^T(k)W(k)H(k) \stackrel{def}{=} P^{-1}(k)$$

לבסוף הקשר הנומרי בין המדידה החדשה למידע הקודם:

$$P^{-1}(k+1) = P^{-1} + h(k+1)w(k+1)h^T(k+1)$$